

8. 이미지 파운데이션 모델



• INDEX

- 파운데이션 모델
- 이미지 생성 모델의 진화
 - GAN
 - Diffusion
 - Latent Diffusion Model
- 멀티 모달
 - CLIP
 - Stable Diffusion
- 지식 증류
 - SANA


The background is a vibrant blue with a complex geometric pattern of overlapping triangles in various shades of blue. A large, white, regular hexagon is centered on the page, outlined with a thin white border. Inside this hexagon, the Korean text '파운데이션 모델' is written in a bold, black, sans-serif font.

파운데이션 모델

✓ 딥러닝 패러다임 변화


- (과거) 개별 태스크(분류, 검출)마다 모델을 처음부터 따로 학습
- (현재) 방대한 데이터로 사전학습된 하나의 모델을 다양한 용도로 재사용

➤ 파운데이션 모델(Foundation Model)




✓ ResNet(CNN) vs Foundation Model(CLIP)


- CNN(ResNet)
 - ImageNet이라는 데이터셋의 1000개 클래스에 대해서만 정답을 맞히도록 훈련되어 있음
 - 따로 배운 개념이 없다면, 사진을 보고 단순 '여우' 라는 결과만 도출
- Foundation Model(CLIP)
 - 4억 개의 이미지-텍스트 쌍을 대조 학습하여, 이미지 속의 사물뿐만 아니라 화풍, 분위기, 동작 등도 함께 학습함
 - 이미지를 설명하는 문장 전체를 하나의 벡터로 이해
 - 예를 들어, "우주에서 서핑하는 고양이" 라는 문장을 "우주", "서핑", "고양이" 개념을 조합해 분류할 수 있음



✓ 파운데이션 모델은 어떻게 강력해졌을까?

- 스케일의 규모
 - 웹상의 수억 개의 이미지와 텍스트를 학습
 - 규모의 법칙: 많이 가르치고, 복잡한 모델일 수록 똑똑하다.
- 자기 지도 학습
 - 레이블이 없는 데이터도, 데이터 자체의 상관관계를 통해 스스로 학습
 - 이미지와 설명 텍스트가 서로 어울려




The background is a vibrant blue with a complex geometric pattern of overlapping triangles in various shades of blue. A large, white hexagon is centered on the page, outlined with a thin white border. Inside this hexagon, the title text is displayed in a bold, black, sans-serif font.

이미지 생성 모델의 진화

GAN


✓ 1세대 - GAN 의 등장

- ✓ 2014년 등장! 적대적 생성 신경망(GAN, Generative Adversarial Network)
- ✓ 현세대 파운데이션 모델로 넘어가기 전, 어떻게 이미지를 만들었는 지를 설명하는 중요한 역할
- ✓ 두 개의 신경망이 서로 경쟁하면서 이미지를 생성
 - ✓ 생성자(Generator)는 "위조범 " 처럼 이미지를 생성
 - ✓ 판별자(Discriminator)는 "경찰 " 처럼 진위를 가려냄
- ✓ 시간이 지날수록 위조범은 더 잘 속이게 되고, 완벽한 위작을 만드는 것을 목표로 학습하게 함




✓ 1세대 - GAN 의 동작 방식

1. 입력: 생성하는 랜덤한 숫자 벡터를 입력받음 (보통 100차원의 벡터)
2. 생성: 입력받은 벡터를 기반으로 이미지를 생성
 - FCL 통과 ($4 \times 4 \times 512$) $\rightarrow$ 업샘플링1 ($8 \times 8 \times 256$) $\rightarrow$ 업샘플링2 ($16 \times 16 \times 128$) $\rightarrow \dots \rightarrow 64 \times 64 \times 3$ 이미지 완성
3. 생성된 이미지에 대해서 생성자의 오차와 판별자의 오차를 구하고, 이를 기반으로 가중치를 업데이트 함




✓ 1세대 - GAN 의 특징

- ✓ 선명하고 사실적인 결과물
- ✓ 생성자가 이미지를 만드는 재료인 '무작위 노이즈'를 조금씩 바꾸면, 이미지도 자연스럽게 바뀜
 - => 처음에 받는 무작위 노이즈가 이미지가 어떤 모습을 가질지 결정하는 역할을 함
 - => 이미지의 특징을 제어할 수 있는 가능성을 열었음



✓ 1세대 - GAN 의 한계

- ✓ 혁신적이었지만... “경찰” 은 너무 똑똑했다.
- ✓ 생성자와 판별자, 두 모델의 균형을 맞추기가 너무 어려웠고, 한 쪽이 똑똑해지면 학습이 제대로 이루어지지 않는 ‘**모드 붕괴**’ 현상이 발생
- ✓ 모드 붕괴
 - ✓ 학습이 진행될수록 생성자가 판별자를 속이기 가장 쉬운, 몇 가지 종류의 이미지만을 반복적으로 생성



Diffusion Model


✓ 2세대 - Diffusion 모델의 등장

- ✓ 2020년 등장한 이미지 파운데이션 모델 이론
- ✓ **노이즈** (원래 형태를 완전히 잃은 이미지) -> 추가된 노이즈를 예측하고, 노이즈를 제거 -> 선명한 이미지 탄생
- ✓ 학습 과정에서 특정 이미지가 망가지는 과정을 학습하고, 이 내용을 기반으로 노이즈를 제거
- ✓ 두 모델이 싸우는 방식(GAN)이 아니라, 노이즈를 예측하는 명확한 수학적 목표를 갖기 때문에 학습이 안정적



✓ 2세대 - Diffusion 모델의 동작 과정

- 순방향 과정(Forward Process, 이미지 파괴)
 - 이미지에 아주 미세한 노이즈를 수천 번에 걸쳐 조금씩 더함
 - 최종적으로 원본의 형태를 완전히 잃어버린 '가우시안 노이즈(정적)' 상태가 됨
- 역방향 과정(Reverse Process, 이미지 복원)
 - 완전한 노이즈(가우시안 노이즈)에서 시작
 - “노이즈 예측기”가 예측한 노이즈를 살짝 걷어냄
 - 위 과정에서 우리가 넣은 노이즈와 예측한 노이즈의 차이를 비교
 - 이 차이를 줄이는 방향으로 가중치를 수정
 - 위 과정을 주어진 횟수에 맞게 반복
 - 단계가 너무 적으면, 형태가 무너짐
 - 단계가 너무 많으면, 정교해지지만 시간이 너무 오래 걸림



✓ 2세대 - Diffusion 모델의 특징

- ✓ '노이즈를 예측하고 제거한다' 는 목표는 안정적이고, 학습에 실패할 확률을 줄임
- ✓ 단계적으로 이미지를 만들어가는 방식 덕분에, "모드 붕괴" 없이 다채로운 결과물을 생성
- ✓ 이미지의 노이즈를 제거하는 각 단계마다 '사용자가 작성한 텍스트' 를 참고하여 훌륭한 결과물을 생성
- ✓ Midjourney, Dall-E, Stable Diffusion 와 같은 이미지 생성 모델의 뿌리



✓ 2세대 - Diffusion 모델 한계

1. 일관성 부족


- ✓ 같은 캐릭터로 다른 포즈나 이미지를 만들려고 하면, 매번 얼굴이나 스타일이 미묘 or 완전히 달라짐
- ✓ 이유: '기억' 의 개념이 없기 때문에, 출발점이 조금씩 달라지면 결과물이 완전히 달라짐

2. 문맥 이해 부족

- ✓ “소파아래, 고양이 옆에 있는 파란 공” 같은 텍스트를 치면, ‘소파, 고양이, 파란 공’ 요소는 그리지만 위치가 형편 없음
- ✓ 텍스트를 이해하는 능력이 부족해서, 전체적인 주제만 파악

3. 느린 속도와 비용

- ✓ 생성 과정이 순차적으로 노이즈를 제거하는 과정



Latent Diffusion Model

✓ Diffusion Model은 너무 속도가 느렸다!

- 이미지의 모든 픽셀에서 직접 노이즈를 계산해야해서 계산량이 너무 많음
 - 이미지를 있는 그대로 다루지 말고, **핵심 특징**만 뽑아낸 “요약본(Latent)” 으로 작업하자!
- Latent Diffusion Model
 - 이미지를 “픽셀 공간”에서 “잠재 공간(Latent Space)”으로 옮겨와서 작업을 수행
 - 픽셀 공간: 우리가 눈으로 보는 실제 이미지 공간(매우 크고 복잡)
 - 잠재 공간(Latent Space): 이미지의 핵심 특징(형태, 색상, 구도)만 압축해 놓은 추상적인 공간 (작고 효율)
 - “픽셀 대신 잠재 공간에서 처리하자”라는 기술적 원리이며 이를 통해 구현한 모델이 **“Stable Diffusion”**

✓ LDM(Latent Diffusion Model)의 동작 과정


1. **Encoder**(압축기)를 활용해 거대한 이미지($512 * 512 * 3$)를 아주 작은 잠재 벡터($64 * 64 * 3$)로 압축
 - Convolution을 반복하여 특징을 뽑아냄
2. 잠재 벡터의 노이즈를 섞고 지우는 작업을 진행
3. **Decoder**(복원기)를 활용해 선명한 이미지($512 * 512 * 3$)로 복원
 - 업샘플링 기술을 활용하여 압축 과정에서 잃어버렸던 세부 픽셀값들을 다시 추측해서 채워 넣음



멀티모달

✓ 멀티모달이란?

- 텍스트, 이미지, 오디오, 비디오 등 서로 다른 형태의 데이터를 함께 이해하고 처리하는 AI 기술
- AI도 인간처럼 세상을 입체적으로 이해하기 위해서는 멀티모달 지능이 필수
- 과거
 - 이미지 모델은 “이 이미지는 고양이입니다” 라는 레이블만 학습
 - 텍스트 모델은 이미지 없이 글자만 학습
- 현재
 - 이미지와 이미지의 “설명”을 통째로 학습시켜, 이미지와 언어를 하나의 개념으로 묶음
- 이러한 멀티모달 시대를 연 주인공, 이미지 생성 AI의 중요한 역할을 하는 모델
 - CLIP(Contrastive Language-Image Pre-training)



CLIP

✓ CLIP(Contrastive Language-Image Pre-training)

- 2021년 OpenAI가 발표한 인공지능 모델 (모델명: clip-vit-base-patch32)
- WIT(WebImage Text)라는 4억개의 이미지-텍스트 쌍을 기반으로 학습
 - 사람이 일일이 정답을 매긴 게 아니라, 사람들이 인터넷에 올린 자연스러운 설명을 학습함
 - 그로 인해 “수채화 풍”, “사이버펑크” 와 같은 추상적인 묘사까지 모두 이해할 수 있음
- “대조 학습”을 기반으로 학습을 진행
 - 이미지와 텍스트를 나란히 두고 서로 맞는지 비교하며 학습
 - **Contrastive** Language-Image Pre-training

✓ CLIP 동작 방식

1. 이미지 인코더와 텍스트 인코더가 각각 사진과 글을 벡터로 변환
 - 변환 후에는 이미지와 텍스트가 비교 가능한 형태가 되며, 좌표값이 된다고 생각하면 됨
2. 만들어진 모든 이미지 벡터와 텍스트 벡터를 각각 쌍으로 보면서 정답이면 가깝게, 오답이면 멀게 설정
 - 이미지 3장, 텍스트 3장이 있다면 총 9가지의 경우의 수를 살펴보며 서로 거리를 조절
 - “코사인 유사도”라는 방법을 통해 거리를 조절
3. 2번 과정을 4억번(데이터 수) 반복하면, 관련 있는 내용들끼리 서로 모여있는 **거대한 잠재 공간**이 만들어 짐
 - 거대한 잠재 공간을 활용해서 “사과 사진” 이미지 근처에는 “사과” 단어도 있기 때문에 근처에 있는 설명이나 단어를 활용해서 결과를 추출함
 - 이로 인해 학습 때 본 적 없는 새로운 문장(“우주에서 서핑하는 고양이”)를 가져와서 각각의 개념을 조합할 수 있음
(Zero-shot Learning)

Stable Diffusion

✓ Stable Diffusion

- LDM(Latent Diffusion Model) + CLIP(Contrastive Language-Image Pre-training)
- 언어 해석 및 잠재 공간 생성(CLIP) -> 압축 및 복원 (LDM)
- LDM 구조 덕분에 슈퍼컴퓨터가 아닌 일반 PC에서도 이미지 생성이 가능해짐
- 모델의 구조와 가중치를 공개하여, 이를 기반으로 수많은 변형 모델들이 탄생함
- <https://github.com/comfvis/stable-diffusion>

Stable Diffusion

Stable Diffusion was made possible thanks to a collaboration with [Stability AI](#) and [Runway](#) and builds upon our previous work:

[High-Resolution Image Synthesis with Latent Diffusion Models](#)

[Robin Rombach*](#), [Andreas Blattmann*](#), [Dominik Lorenz](#), [Patrick Esser](#), [Björn Ommer](#)

[CVPR '22 Oral](#) | [GitHub](#) | [arXiv](#) | [Project page](#)



[Stable Diffusion](#) is a latent text-to-image diffusion model. Thanks to a generous compute donation from [Stability AI](#) and support from [LAION](#), we were able to train a Latent Diffusion Model on 512x512 images from a subset of the [LAION-5B](#) database. Similar to Google's [Imagen](#), this model uses a frozen CLIP ViT-L/14 text encoder to condition the model on text prompts. With its 860M UNet and 123M text encoder, the model is relatively lightweight and runs on a GPU with at least 10GB VRAM. See [this section](#) below and the [model card](#).

✓ Stable Diffusion의 현실적인 한계


- 추론 속도(Latency)
 - 20~50단계의 반복 연산이 필요하여 실시간 생성에는 여전히 느린 속도
- 의미론적 오류
 - 복잡한 문장의 형용사와 명사를 혼동하는 경우가 잦음
- 구조적 결함
 - 인간의 손가락 개수, 복잡한 문자 표시 등 세밀한 논리 구조에서 오류가 발생
- 높은 하드웨어 성능

➤ 거대 모델의 지능은 그대로 가져오고, 크기를 줄일 수는 없을까????

지식증류

✓ 지식 증류(Knowledge Distillation)

- 방대한 지식을 작고 가벼운 모델에게 효율적으로 전달하는 모델 압축 기술
- 단순히 결과값만 전달하는 것이 아니라, 문제를 해결하는 사고방식을 가르치는 것
- Teacher Model의 확률 분포를 Student Model 이 학습함으로써, 적은 파라미터로도 정교한 판단 능력을 배움



✓ 지식 증류를 하는 이유

- 경량화
 - 모델의 크기를 수십 배까지 줄일 수 있음
 - 모바일이나 웹 브라우저에서도 구동 가능
- 속도
 - 연산량이 적어 추론 속도가 빨라짐
 - 실시간 이미지 생성 및 서비스 운영 비용을 절감할 수 있음
- 성능 유지
 - 크기는 작아졌지만, 거대 모델의 지능을 상당부분 유지

SANA

✓ SANA

- Efficient High-Resolution Image Synthesis with Linear Diffusion Transformers
- LDM+CLIP+지식증류
- 엔비디아에서 개발하여 배포한 모델
- 아주 적은 컴퓨팅 자원으로도 4K 해상도 이미지를 빠르게 만들 수 있음
- <https://github.com/NVlabs/Sana>



 Docs | [SANA](#) | [SANA-1.5](#) | [SANA-Sprint](#) | [SANA-Video](#) | [Demo](#) |  [HuggingFace](#)
[ComfyUI](#) | [SGLang](#) | [Cosmos-RL](#)

